

รายงานสรุป Data Integration & Data Quality

1. สรุปคุณภาพข้อมูล (ก่อนและหลัง Data Integration)

ขั้นตอน	ตารางข้อมูล	ค่าว่าง	ข้อมูลซ้ำ	สถานะ
ก่อนทำ	ข้อมูลลูกค้า	พบค่าว่าง	พบข้อมูลซ้ำ	รอการแก้ไข
ก่อนทำ	ข้อมูลคำสั่งซื้อ	พบค่าว่างในส่วนลด	พบรายการซ้ำ	รอการแก้ไข
หลังทำ	Fact_Sales	0 (เติม 0 ในส่วนลด)	0 (ลบข้อมูลซ้ำแล้ว)	พร้อมวิเคราะห์

2. คำตอบสำหรับคำถามวิเคราะห์ 6 ข้อ

ข้อที่1: จังหวัดใดมียอดขายรวม (Net Sales) สูงที่สุด?

ตอบ: นำชื่อจังหวัดลำดับที่ 1 จากไฟล์ summary_by_province.csv มาตอบ

ข้อที่2: หมวดหมู่สินค้าใดที่สร้างยอดขายได้มากที่สุด?

ตอบ: นำชื่อหมวดหมู่จากไฟล์ summary_by_category.csv มาตอบ

ข้อที่3: ข้อมูลลูกค้าก่อนทำความสะอาดมีปัญหาอะไรบ้าง?

ตอบ: มีรูปแบบอีเมลที่เป็นพิมพ์เล็ก/ใหญ่ผสมกัน, ชื่อจังหวัดมีช่องว่างเกินมา และมีข้อมูลลูกค้ารหัสซ้ำซ้อนกัน

ข้อที่4: การจัดการกับค่าว่าง (Missing Value) ในคอลัมน์ Discount ใช้วิธีใด?

ตอบ: ใช้วิธีเติมค่าศูนย์ (0) ลงไปแทนค่าว่าง (fillna(0)) เนื่องจากหากไม่มีส่วนลด แปลว่าส่วนลดคือ 0%

ข้อที่5: ข้อมูลในไฟล์ JSON สาเหตุใดถึงใช้ .duplicated() ตรงๆ ไม่ได้และแก้ปัญหายังไง?

ตอบ: เพราะมีโครงสร้างข้อมูลซ้อนกันแบบ Dictionary (Unhashable type) แก้ไขโดยการแปลงข้อมูลเป็น String ชั่วคราว (.astype(str)) ก่อนทำการนับตัวซ้ำ

ข้อที่6: ประโยชน์ของการแยกตารางเป็น Dimension และ Fact Table คืออะไร?

ตอบ: ช่วยลดความซ้ำซ้อนของข้อมูล (Data Redundancy) ทำให้ฐานข้อมูลเป็นระเบียบ และเพิ่มประสิทธิภาพความเร็วในการดึงข้อมูลไปทำ Dashboard หรือวิเคราะห์ต่อ